Projet NLP 2 — Cadrage J2

Détection et interprétation d'anomalies dans les logs HDFS

21 septembre 2026 — TeamAI
Alain, Nassim, Bachar et Linda

Volet A	Classification binaire de traces HDFS avec un modèle entraîné par le groupe, export ONNX et inférence navigateur.
Volet B	Interprétation sourcée de traces avec un SLM adapté, un RAG et trois agents partageant le même modèle.
Données candidates	HDFS_v1 de Loghub ; documentation HDFS et exemples d'interprétation à préparer.
Objectif J2	Présenter le sujet et le cadrage ; déclarer les environnements ; créer le board ; identifier la machine et les essais de faisabilité.

1. Problématique et valeur du sujet

Comment détecter des traces anormales dans des logs HDFS et aider à les interpréter à partir d'une documentation technique ?

Le volet A classe des traces en « normal » ou « anomalie ». Le volet B utilise un petit modèle de langage adapté pour résumer les événements et proposer une interprétation sourcée. Il distingue les faits observés des hypothèses, sans garantir la cause d'une panne. Les deux applications fonctionnent indépendamment.

2. Environnement de développement proposé

• Python pour la préparation des données, l'entraînement et l'évaluation des modèles.

• VS Code et/ou Jupyter Notebook : choix et système d'exploitation à déclarer par chaque membre.

• Git / GitHub pour le versionnement et le travail collaboratif.

• HTML, CSS et JavaScript pour l'application web du volet A.

• ONNX Runtime Web pour exécuter le modèle du volet A directement dans le navigateur.

• PyTorch pour les modèles ; Transformers et PEFT pour le SLM et LoRA. Versions à fixer après les premiers essais. Ces choix ne constituent pas encore une déclaration des environnements installés.

3. Board de tickets

Le board doit être créé pour J2, avec les quatre membres et les colonnes Backlog, À faire, En cours, À relire et Terminé. Il peut encore être vide à ce jalon. Sa création reste à effectuer ; le lien sera ajouté une fois les accès vérifiés.

Chaque ticket de développement précisera le composant, le responsable, le relecteur, l'échéance et les critères de fin. Les tickets seront créés avant la réalisation du travail.

Dépôt : https://github.com/LindaBOUKHIT/TeamAI
Board et suivi partagé : liens à renseigner après création et vérification des accès.

Exemple de ticket : « Développer le regroupement par identifiant de bloc ». Responsable proposé : Nassim ; relecteur : Bachar. Critères de fin : traces reproductibles, cas avec plusieurs identifiants documentés, lignes inexploitables comptées et exemple de contrôle vérifié. Échéance cible : 25 septembre.

4. Étude du volet A — Application web

Élément	Choix envisagé
Cas d'usage	Classification de traces HDFS_v1 en normal/anomalie.
Entrée	Extrait de logs au format HDFS documenté ; regroupement par identifiant de bloc. Signaler les traces incomplètes lorsqu'elles sont identifiables.
Modèle	BiLSTM sur les séquences prétraitées ; référence fondée sur les fréquences d'événements et une régression logistique.
Données candidates	HDFS_v1 ; audit et échantillonnage de traces complètes à réaliser.
Sortie	Classe normal/anomalie, score du modèle et export des résultats par trace.
Déploiement	Export ONNX puis inférence côté client avec ONNX Runtime Web.
Faisabilité navigateur	Architecture envisagée ; export ONNX, prétraitement et exécution navigateur à vérifier sur un prototype.

Périmètre retenu pour les premiers essais : HDFS_v1, classification binaire par trace regroupée par identifiant de bloc. Séparer les jeux par bloc et contrôler les doublons. Le prétraitement sera appris sur le jeu d'entraînement uniquement. Mesurer précision et rappel des anomalies, macro-F1, matrice de confusion et latence. Les scores du modèle ne seront pas présentés comme des probabilités calibrées.

5. Étude du volet B — Application locale

Élément	Choix envisagé
Cas d'usage	Aide à l'interprétation d'une trace, avec distinction entre faits observés et hypothèses.
Modèle candidat	SmolLM2-1.7B-Instruct, sous réserve de validation matérielle.
Architecture	SLM local, RAG sur documentation HDFS et trois agents de recherche, rédaction et contrôle.
Adaptation	Adaptation supervisée par LoRA sur exemples vérifiés. Faisabilité matérielle à tester rapidement ; adapter la taille du modèle si nécessaire.
Entrées	Logs ou extraits pertinents + consigne d'analyse.
Sortie	Résumé et interprétation avec références ; informations manquantes signalées, abstention si nécessaire. Aucune correction automatique.

Élément	Choix envisagé
Évaluation	Comparer SLM initial, SLM initial avec RAG, SLM adapté avec RAG, puis version multi-agent. Mesurer exactitude des faits, sources, abstention, latence et mémoire.

Les agents s'exécutent successivement sur une même instance du SLM. Une seule reprise de la réponse est autorisée, avec au plus cinq appels au modèle. L'agent de contrôle peut accepter, demander une correction ou signaler un manque de preuves ; son avis ne remplace pas l'évaluation humaine.

Machine locale à identifier : membre propriétaire, système, CPU, RAM, GPU et VRAM à renseigner. L'inférence et l'adaptation feront l'objet de deux essais distincts.

Pour 1,7 milliard de paramètres, les poids seuls représentent environ 0,85 Go en 4 bits ou 3,4 Go en 16 bits. Il faut ajouter les métadonnées, le cache, les activations et les bibliothèques. Ce calcul ne donne pas la mémoire totale nécessaire, notamment pour LoRA. Mesurer celle-ci avant de confirmer le modèle ; réduire sa taille ou le contexte si nécessaire.

6. Données et corpus

Volet A : HDFS_v1 de Loghub. Auditer le format, les doublons et le déséquilibre des classes avant de sélectionner quelques milliers de traces complètes. Conserver une séparation reproductible entre apprentissage, validation et test. Les données n'ont pas encore été téléchargées ni préparées par le groupe.

Volet B : documentation HDFS sélectionnée et versionnée. Les étiquettes normal/anomalie ne fournissent pas les explications nécessaires à l'adaptation. Le groupe constituera donc des exemples vérifiés reliant traces, observations et sources, ainsi qu'un jeu de test distinct comprenant des cas insuffisamment documentés. Une partie des réponses sera évaluée par deux membres avec une grille commune.

Source des annotations HDFS_v1 : https://github.com/logpai/loghub/tree/master/HDFS. La documentation sera choisie en tenant compte de la version du système ; une procédure générale ne sera pas présentée comme une cause démontrée.

7. Périmètre, risques et critères de réussite

Périmètre	Risques principaux	Critères de réussite
HDFS uniquement. Application web et application locale indépendantes. Pas de supervision temps réel, de diagnostic causal garanti ni d'action sur un système.	Classes déséquilibrées ou fuites entre jeux. Export ONNX incompatible. Documentation ou exemples insuffisants. Mémoire insuffisante pour LoRA. Réponses non fondées ; surcoût des agents.	Site public avec inférence navigateur. Évaluation sur test réservé. SLM adapté avec mesures avant/après. Réponses sourcées. Apport des agents mesuré face à un agent.

8. Répartition initiale proposée

Responsabilité	Domaine principal	Domaine secondaire / relecture
Nassim	Données : audit HDFS_v1, prétraitement et séparation des jeux.	Avec Bachar : relecture du classifieur et de son évaluation.
Bachar	Volet A : référence, BiLSTM, export ONNX et interface web.	Avec Nassim : contrôle des données et tests de préparation.
Alain	SLM : essais matériels, adaptation et mesures avant/après.	Avec Linda : relecture du RAG et des agents.
Linda	Documentation, RAG, agents et interface locale.	Avec Alain : relecture de l'adaptation et de l'évaluation.

Cette répartition est une proposition à confirmer par les quatre membres. Tous participent aux annotations, à l'évaluation, au rapport et aux démonstrations. Chaque ticket indique son responsable et son relecteur.

9. Actions pour J2 et premiers essais

☐ Pour J2 : confirmer la répartition nominative et déclarer les environnements de chaque membre.

☐ Pour J2 : identifier la machine locale et compléter ses caractéristiques ; vérifier ensuite l'inférence et l'adaptation.

☐ Pour J2 : créer le board, ajouter les quatre membres et donner accès à l'enseignant. Partager le suivi et le journal des usages d'IA.

☐ Après J2 : auditer HDFS_v1, préparer les traces et entraîner la méthode de référence.

☐ Après J2 : tester l'export ONNX et comparer les prédictions Python et navigateur.

☐ Pour le 01/10 : déployer une version web minimale et réussir une première inférence locale.

☐ Préparer la documentation HDFS, les exemples d'adaptation et le test réservé ; commencer par un RAG à un agent avant la version à trois agents.

10. Jalons de référence

J2 — 21/09/2026 : environnement déclaré, board créé, étude des deux volets, machine cible et cadrage initial.

01/10/2026 : volet A déployé, même minimalement ; première inférence locale aboutie pour le volet B ; tag Git et capture du board.

16/10/2026 : volet A fonctionnel, adaptation engagée et supports préparés, même incomplets. Commencer le rapport au plus tard à J3.

Avant le 07/12/2026 : site public fonctionnel et V1 du rapport PDF remis. Le 07/12 : soutenance, supports de pitch et de présentation transmis ; démonstration locale ou vidéo disponible.