FACULTÉ GESTION, ÉCONOMIE, SCIENCES
Université Catholique de Lille 1875

ÉCOLE DU NUMÉRIQUE

NLP 2 · M2 Data & IA — revue d'avancement J3

Que nous disent les logs HDFS ?

Repérer les blocs qui tournent mal, puis expliquer pourquoi : deux approches, une même équipe.

TeamAI

Alain Evina · Nassim Mezzai · Bachar Ben Slama · Linda Boukhit

Enseignant : **Adrian Rosari**

HDFS.log — un bloc, quatre lignes

```
1 081110 010451 33 INFO dfs.FSNamesystem: BLOCK* N
  ameSystem.allocateBlock: /user/root/randtxt/_tem
  porary/_task_200811092030_0003_m_000269_0/part-…
2 081110 010451 5105 INFO dfs.DataNode$DataXceive
  r: Receiving block blk_-1013481023655112960 src:
  /10.251.74.134:45275 dest: /10.251.74.134:50010
3 081110 010451 5109 INFO dfs.DataNode$DataXceive
  r: Receiving block blk_-1013481023655112960 src:
  /10.251.74.134:48604 dest: /10.251.74.134:50010
4 081110 010454 5105 INFO dfs.DataNode$DataXceive
  r: writeBlock blk_-1013481023655112960 received
  exception java.io.IOException: Could not read f…
```

là, ça casse. mais pourquoi ?

Le point de départ

Des centaines de milliers de blocs, et quelques pannes discrètes

575 061

blocs HDFS annotés

Loghub HDFS_v1, logs de 2008

2,93 %

d'anomalies seulement

16 838 blocs : classes très déséquilibrées

29

types d'événements

de E1 à E29

Un label « anomalie » dit qu'il y a un problème… jamais pourquoi.

C'est toute la raison d'être du volet B.

Notre réponse

Deux façons de lire les mêmes logs

VOLET A

Le guetteur

« Ce bloc est-il normal ? »

- Un BiLSTM **entraîné par nous**, exporté en ONNX
- Il tourne **dans le navigateur**, sans serveur
- Site statique, coût nul (GitHub Pages)
- Rapide, léger, entièrement maîtrisé

les logs bruts

VOLET B

L'explicateur

« Que s'est-il passé, et sur quoi je m'appuie ? »

- SmolLM2-1.7B, un modèle ouvert, **en local**
- Adapté par LoRA sur des exemples annotés
- RAG sur la documentation officielle HDFS
- Faits, hypothèses, sources… ou « je ne sais pas »

Sept contrats d'échange (C1 à C7) fixent ce que chaque partie transmet aux autres : traces, vocabulaire, modèle, découpage, réponses, passages, évaluations.

Qui fait quoi

Quatre personnes, un seul dépôt

AE

Alain Evina

SLM et adaptation

- ✓ Première inférence de SmolLM2
- ✓ Version 4 bits du modèle
- ✓ Tests et intégration continue
- ✓ Essai LoRA (en cours)

NM

Nassim Mezzai

Données

- ✓ Audit du corpus HDFS
- ✓ Parser et découpage reproductible
- ✓ Baseline de référence
- ✓ Format des logs du site

BB

Bachar Ben Slama

Volet A et site

- ✓ Export ONNX validé
- ✓ BiLSTM v1 entraîné
- ✓ Site v0 avec modèle en cache

LB

Linda Boukhit

RAG et organisation

- ✓ Corpus documentaire HDFS
- ✓ Prétraitement JS identique au Python
- ✓ Grille d'annotation (en relecture)
- ✓ Classeur partagé de l'équipe

Les données

Un seul découpage, et on ne triche pas



Tiré bloc par bloc

Découpage stratifié (seed 42) : chaque partie garde 2,93 % d'anomalies. Tous les modèles de l'équipe utilisent exactement le même.

Seulement 18 373 séquences distinctes !

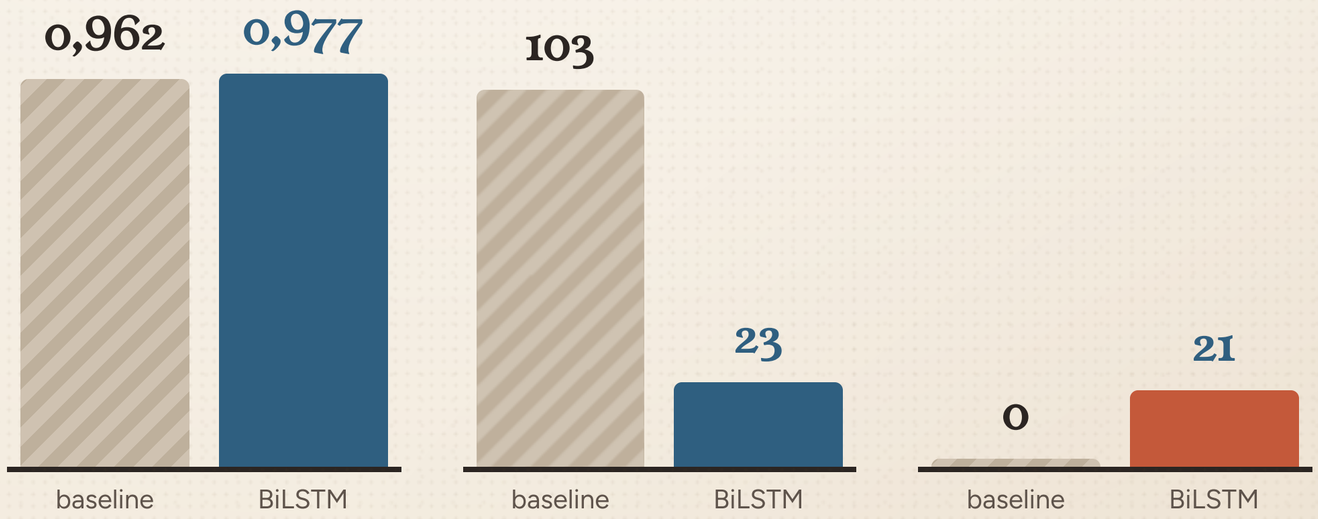
Beaucoup de blocs se ressemblent. On donne donc toujours deux scores : sur tout l'ensemble, et sur les **séquences jamais vues**, qui mesurent la vraie généralisation.

Le test reste fermé

Aucun réglage, seuil ou exemple n'en est tiré : la règle est vérifiée automatiquement à chaque pull request.

Volet A · premiers résultats

Le BiLSTM fait mieux que la baseline, à un prix près



Macro-F1 sur les séquences jamais vues
meilleure généralisation

Fausses alertes (validation)
4,5× moins

Anomalies manquées (validation)
le prix à payer

0,996
macro-F1 sur les 86 259 blocs de validation

$1{,}2\times10^{-7}$
écart maximal PyTorch / ONNX, 0 classement changé

100 %
des 575 061 blocs prétraités à l'identique en JavaScript et en Python

Seuil choisi sur la validation : 0,99, au bord de la grille testée → à réexaminer.

Mesures sur la validation. Le test officiel n'a pas encore été ouvert.

Volet B · premiers pas

Le modèle parle déjà… mais pas encore juste

1

Première inférence

SmolLM2-1.7B sur CPU : moins d'un token par seconde. Il ignore les WARN et invente des détails.

2

Version 4 bits

Environ trois fois plus rapide, 2,8 Go de mémoire au lieu de 16.

3

Corpus RAG

51 passages de la doc HDFS. 19 événements n'ont aucun passage qui les explique.

4

Grille d'annotation

Une note sur 8 et trois exemples de calibration, dont une abstention.

5

Essai LoRA

Chaîne validée sur CPU (2 pas, adaptateur rechargé). Les 30 pas se lanceront sur GPU, en 4 bits.

Observations sur une seule trace : ce n'est pas encore une évaluation.

Notre façon de travailler

Un ticket, une branche, une relecture

Ticket → Branche → Pull request → **Relecture croisée** → dev → main · site en ligne

20

pull requests fusionnées, chacune reliée à son ticket

Tests à chaque PR

Formats des contrats, docstrings, parité JavaScript / Python, test jamais utilisé pour régler.

Un journal honnête

Chaque mesure garde sa commande, sa machine et ses limites. L'usage de l'IA y est tracé.

Où on en est

Le point, sans maquillage

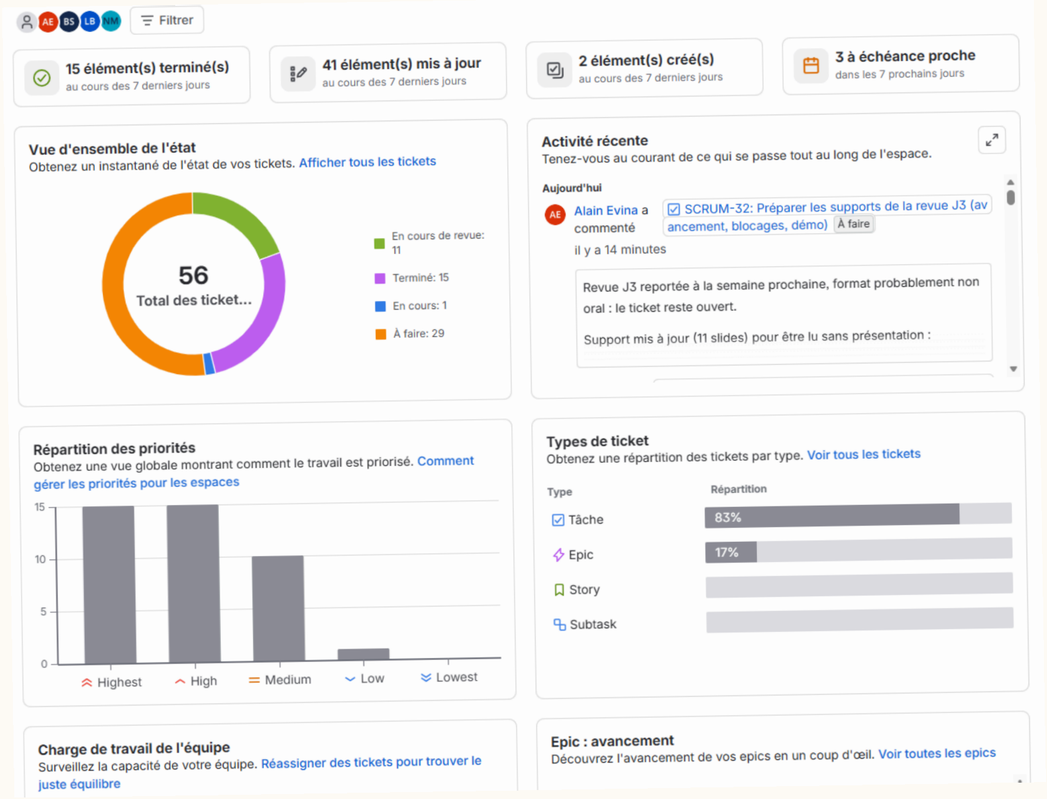
- [x] **Données, découpage et baseline**
  reproductibles, partagés par toute l'équipe
- [x] **BiLSTM v1 exporté en ONNX**
  parité validée, embarqué dans le site
- [-] **Site prêt, pas encore publié**
  reste la fusion de dev dans main pour GitHub Pages
- [-] **Adaptation LoRA engagée**
  chaîne validée sur CPU, essai GPU à lancer
- [x] **Jalon de mi-parcours manqué**
  preuves rassemblées, version taguée dès la mise en ligne
- [x] **Équipe réalignée**
  contrats v1.1, relecture des PR sous 48 h

Ce qu'on a appris

Commencer par se mettre d'accord sur les formats. Ne jamais laisser une PR ouverte des jours. Mesurer avant d'affirmer.

Le pilotage

Jira, tel qu'on l'utilise



56

tickets, chacun avec un responsable, un relecteur et un critère de fin

15 terminés

11 en revue

1 en cours

29 à faire

41 tickets mis à jour en 7 jours

À vous de jouer

Le vérifier par soi-même

Dans le navigateur

Coller des logs ou choisir un exemple, voir le score de chaque bloc. Le modèle est gardé en cache après le premier chargement.

```
lindaboukhit.github.io/TeamAI
```

publication en cours

En local

Le SLM en version 4 bits sur une trace anormale : réponse structurée et mesures.

```
python -m volet_b.slm.bench_gguf
```

commandes détaillées dans les README

Code : github.com/LindaBOUKHIT/TeamAI, branche dev.

Et maintenant

Sprint 2 : adapter, chercher, comparer

Volet A

- Évaluer sur le test officiel
- Réexaminer le seuil de décision
- Parcours complet : lot, résultats par bloc, export CSV

Volet B

- Jeu de test réservé et exemples relus
- Mesures « avant adaptation », sans et avec RAG
- LoRA complet, chaque essai consigné

Nos questions

Quel périmètre attendez-vous pour l'adaptation ?
Sous quelle forme présenter la comparaison entre les deux volets ?

merci !

Alain, Nassim, Bachar et Linda